

Final Project Report

ชื่อโครงการ
การจำแนกสายพันธุ์ผีเสื้อด้วย Deep Learning (Butterfly Species Classification)

สมาชิก

พิจักษณ์ ลิมล้ำเลิศกุล 6610502161

กิรณา รักประกอบกิจ 6610505284

การเรียนรู้เชิงลึก (Deep Learning) 204466

1. หัวข้อและความน่าสนใจของโครงงาน

ผู้เขียนเป็นสิ่งมีชีวิตที่มีความหลากหลายของลวดลายและสีสันอย่างมาก การจำแนกสายพันธุ์ด้วยตาเปล่ามักต้องอาศัยผู้เชี่ยวชาญ และอาจเกิดความคลาดเคลื่อนสูง การใช้ Deep Learning เข้ามาช่วยสามารถเพิ่มความแม่นยำและลดเวลาในการจำแนกสายพันธุ์ได้อย่างมาก

เราจึงเลือกทำหัวข้อ “การจำแนกสายพันธุ์ผีเสื้อ (Butterfly Species Classification)” โดยใช้ภาพถ่ายและเทคนิค Convolutional Neural Network (CNN) เพื่อให้ระบบสามารถเรียนรู้ลักษณะเฉพาะ เช่น ลวดลาย สี ปีก และโครงสร้างร่างกายของผีเสื้อได้ด้วยตนเอง

2. เหตุผลที่เลือกใช้ Deep Learning

การจำแนกสายพันธุ์ผีเสื้อจากภาพถ่ายเป็นปัญหาที่ซับซ้อน เพราะลักษณะของผีเสื้อมีความคล้ายคลึงกันสูงในหลายสายพันธุ์ เช่น รูปแบบของปีก สี หรือแม้แต่โครงสร้างเส้นลายที่ละเอียดอ่อน ซึ่งบางครั้งความแตกต่างอาจอยู่ในรายละเอียดระดับจุดสีหรือเส้นขนเล็กๆ ที่ตาเปล่ามองแทบไม่เห็น การใช้เทคนิคปกติของ Machine Learning หรือการประมวลผลภาพแบบดั้งเดิมจึงมักให้ผลลัพธ์ที่จำกัด เพราะต้องอาศัย “การออกแบบคุณลักษณะ” (Feature Engineering) ด้วยมือ ซึ่งไม่สามารถจับรายละเอียดเชิงลึกของภาพได้ดีพอ

2.1 การเปรียบเทียบกับวิธีตั้งเดิม

ก่อนยุคของ Deep Learning การจำแนกภาพมักใช้กระบวนการสองขั้นตอนคือ

1. การทำ Feature Extraction เช่น การใช้ Histogram of Oriented Gradients (HOG), Scale-Invariant Feature Transform (SIFT), หรือ Local Binary Pattern (LBP) เพื่อดึงข้อมูลเชิงลวดลายหรือขอบออกมาจากภาพ
2. การจำแนก (Classification) โดยใช้โมเดลอย่าง SVM, k-NN หรือ Random Forest

แม้ว่าวิธีเหล่านี้จะให้ผลลัพธ์ที่ดีในบางกรณี แต่มีข้อจำกัดคือ

- ต้องออกแบบ Feature ด้วยมือ และ Feature ที่เหมาะสมกันนี้มีเงื่อนไขหนึ่งขั้นตอน อาจใช้ไม่ได้กับอีกชนิด
- ไม่สามารถจับความสัมพันธ์เชิงพื้นที่และลำดับขั้นของภาพได้ (เช่น ลายบนปีกที่สัมพันธ์กับโครงร่างโดยรวม)
- ประสิทธิภาพลดลงมากเมื่อภาพมีแสง มุกกล้อง หรือพื้นหลังที่แตกต่างกัน

2.2 ข้อดีของ Deep Learning ในปัจจุบันนี้

การใช้ Deep Learning โดยเฉพาะสถาปัตยกรรมแบบ Convolutional Neural Network (CNN) ช่วยแก้ไขจำกัดเหล่านี้ได้อย่างมีประสิทธิภาพ เพราะ CNN สามารถ “เรียนรู้ Feature เอง” ได้โดยไม่ต้องให้มุ่งเน้นออกแบบล่วงหน้า ชั้นแรกๆ ของ CNN จะเรียนรู้ Feature พื้นฐาน เช่น ขอบและสี ส่วนชั้นลึกๆ จะเรียนรู้โครงสร้างที่ซับซ้อนขึ้น เช่น รูปร่าง ลวดลาย หรือสัดส่วนของปีก ซึ่งตรงกับธรรมชาติของภาพผู้เสื่อมอย่างมาก

นอกจากนี้ การใช้ Transfer Learning จากโมเดลที่ผ่านการฝึกบน ImageNet ซึ่งมีภาพหลากหลายประเภทอยู่แล้ว ทำให้โมเดลนี้ “ความเข้าใจเบื้องต้น ก็ยังกับภาพทั่วไป” เช่น การแยกแสง เจ้า พื้นผิว และลวดลาย เมื่อเรานำโมเดลนั้นมาปรับจูนกับข้อมูลผู้เสื่อม (Fine-tuning) จึงสามารถเรียนรู้ได้เร็วขึ้น ใช้ข้อมูลน้อยลง แต่ยังให้ความแม่นยำสูง

อีกเหตุผลที่สำคัญคือ Deep Learning สามารถประมวลผลภาพหลายหมื่นภาพพร้อมกันได้ผ่าน GPU โดยใช้เทคนิค mini-batch training และ parallel computation ซึ่งช่วยให้การเทรนโมเดลในโครงการนี้สามารถทำได้ภายในระยะเวลาอันสั้นบนแพลตฟอร์ม Google Colab

3. สถาปัตยกรรมของโมเดล (Model Architecture)

โมเดลที่ใช้ในโครงการนี้เป็น Convolutional Neural Network (CNN) โดยใช้แนวคิด Transfer Learning ร่วมกับโมเดล MobileNetV2 ซึ่งเป็นหนึ่งในสถาปัตยกรรม CNN ที่ได้รับการออกแบบมาให้มีรากน้ำดีเก็ต แต่ยังคงความแม่นยำสูงในการจำแนกภาพ

3.1 ภาพรวมของโครงสร้างโมเดล สถาปัตยกรรมของโมเดลแบ่งออกเป็นสองส่วนหลัก คือ

1. **ส่วนฐาน (Base Model):** ใช้ MobileNetV2 ที่ผ่านการฝึกมาก่อนบนชุดข้อมูล ImageNet ซึ่งมีภาพกว่า 1.2 ล้านภาพ 1,000 หมวดหมู่ บทบาทของส่วนนี้คือ “ดึงคุณลักษณะ (Feature Extraction)” จากภาพ เช่น ลวดลาย สี และขอบของปีกผู้เสื่อม โดยไม่ต้องฝึกใหม่ทั้งหมด
2. **ส่วนหัวจำแนก (Classifier Head):** เป็นชั้นที่ออกแบบใหม่เพื่อจำแนก “สายพันธุ์ผู้เสื่อม 75 ชนิด” ตามโจทย์ของเรา โดยใช้โครงสร้าง Fully Connected Layers ร่วมกับ Dropout เพื่อลด overfitting

3.2 รายละเอียดของ MobileNetV2

MobileNetV2 เป็นสถาปัตยกรรม CNN แบบ “ประยุกต์พารามิเตอร์” (parameter-efficient) ที่ใช้ **Depthwise Separable Convolution** แทนการคุณ化อุปกรณ์ ซึ่งแยกขั้นตอนการ “กรอง” (filtering) และ “รวมข้อมูล” (combining features) ออกจากกัน เพื่อให้ไม่เดลเบาแต่ยังคงความสามารถในการเรียนรู้ ลดลง

ภายในของ MobileNetV2 ประกอบด้วยโครงสร้างที่เรียกว่า **Inverted Residual Block** ซึ่งประกอบด้วย 3 ขั้นตอนหลัก:

1. **Expansion (1x1 convolution)**: ขยายจำนวน channel เพื่อเพิ่มความสามารถในการเรียนรู้ feature ที่ซับซ้อน
2. **Depthwise Convolution (3x3)**: ดึงข้อมูลเชิงพื้นที่ (spatial feature) ของแต่ละ channel แยกจากกัน
3. **Projection (1x1 convolution)**: ลดจำนวน channel กลับเพื่อลดขนาดของโมเดล

ทุกบล็อกจะใช้ **Batch Normalization** และ **ReLU6** เป็น activation function เพื่อให้การเรียนรู้เสถียรขึ้นและป้องกัน gradient vanishing

3.3 ส่วนหัวจำแนก (Classifier Head)

หลังจาก MobileNetV2 ดึง feature ได้แล้ว ผลลัพธ์สุดท้ายจะถูกป้อนเข้าสู่ส่วนหัวจำแนกที่เราออกแบบเอง โดยมีรายละเอียดดังนี้:

- **GlobalAveragePooling2D**: ลดขนาดข้อมูลจาก 3 มิติ (feature map) ให้กล้ายเป็นเกลือเตอร์เดียว เพื่อเตรียมต่อ กับขั้น Fully Connected
- **Dropout (rate = 0.3)**: ปิดการทำงานของ neuron บางส่วนแบบสุ่มในระหว่างการฝึก เพื่อป้องกัน overfitting
- **Dense(128, ReLU)**: ชั้นซ่อน (hidden layer) ที่ช่วยให้โมเดลเรียนรู้ความสัมพันธ์เชิงไม่เส้นของ feature
- **Dense(75, Softmax)**: ชั้นเอาร์ทพุตที่ให้ผลลัพธ์เป็นความน่าจะเป็นของฝีเสื้อแต่ละสายพันธุ์ (รวมกันเท่ากับ 1)

3.4 ขั้นตอนการฝึก (Training Phases)

เราแบ่งการฝึกโมเดลออกเป็น 2 ช่วงเพื่อให้การเรียนรู้มีประสิทธิภาพ:

1. **Phase 1 – Feature Extraction:**
“แข็งแข็ง” นำหนักทั้งหมดของ MobileNetV2 และฝึกเฉพาะส่วนหัวจำแนก (Classifier Head) เพื่อให้ชั้นใหม่เรียนรู้การจำแนกพื้นฐานก่อน
2. **Phase 2 – Fine-Tuning:**
“คลายๆ” (unfreeze) บางชั้นบนสุดของ MobileNetV2 และฝึกต่อด้วย learning rate ที่เล็กลง เพื่อปรับจูนให้โมเดลเรียนรู้ feature เฉพาะของฝีเสื้อ โดยไม่ทำลายความรู้เดิมจาก ImageNet

3.5 Activation Function และ Hyperparameters

- Activation:
 - ใช้ ReLU6 ภายใน MobileNetV2 เพื่อรับรับข้อมูลที่ normalized
 - ใช้ ReLU ในชั้น Dense ซ่อน
 - ใช้ Softmax สำหรับเอาต์พุตหลายคลาส (multi-class classification)
- Optimizer: Adam
- Loss Function: Categorical Crossentropy
- Batch Size: 32
- Epochs: 20 (10 + 10 สำหรับ Fine-tuning)

3.6 ภาพของโมเดล




Figure 1: Model Architecture of Butterfly Species Classification (MobileNetV2 + Classifier Head)

The input image passes through normalization and MobileNetV2 feature extractor, followed by GlobalAveragePooling, Dropout, and Dense layers to output 75 butterfly classes.




Figure 2: Fully Connected Classifier Head showing 128–64–75 architecture with weights, bias units, and activation functions (ReLU, Softmax).

4. การอธิบายโค้ด (Code Explanation)

Section 1: Setup and Data Import

- ติดตั้ง `kaggle` และตั้งค่าข้อมูลจาก Kaggle API
- แตกไฟล์ `.zip` และจัดการ path

Section 2: Data Preprocessing

- อ่านไฟล์ `Training_set.csv` ด้วย pandas
- ใช้ `train_test_split` แบ่งข้อมูล Train (80%), Validation (10%), และ Test (10%)
- ใช้ `tf.data.Dataset` สำหรับ pipeline ที่อ่านภาพ ปรับขนาด และทำ augmentation (`RandomFlip`, `RandomRotation`, `RandomZoom`)

Section 3: Model Building

- โหลด MobileNetV2 (`include_top=False`)
- เพิ่ม Classifier Head (GlobalAveragePooling, Dropout, Dense) ที่ส่วนท้าย

Section 4: Model Training

- ใช้ optimizer: Adam
- Loss function: Categorical Crossentropy
- Metric: Accuracy

Section 5: Evaluate & Visualization

- วัดค่า accuracy และ loss ของ train และ validation
- ผลลัพธ์ตามรูปแนบ

Section 6: Detailed Analysis

- ทดสอบโมเดลกับ Test Set (10% ที่เราแบ่งไว้)
- แสดงตัวอย่างการทำนาย (Prediction)
- แสดง Confusion Matrix และ Classification Report

Section 7: Conclusion

- สรุปผลลัพธ์ของโครงการ

5. ข้อมูลชุดข้อมูล (Dataset Description)

แหล่งที่มา: [Kaggle – Butterfly Image Classification](#)

จำนวนภาพ: ~38,000 ภาพ

จำนวนสายพันธุ์: 75 ชนิด

ภาพขนาดเฉลี่ย: 224x224 พิกเซล

รูปแบบข้อมูล:

- โฟลเดอร์ `train/`, `test/` เก็บภาพทั้งหมด
- ไฟล์ `Training_set.csv` ระบุชื่อไฟล์และ label ของแต่ละภาพ

การเตรียมข้อมูล:

- Normalize พิกเซลให้อยู่ระหว่าง 0–1
- ใช้ one-hot encoding สำหรับ label
- Augmentation เพื่อเพิ่มความหลากหลายของข้อมูล

6. การเทรนโมเดล (Model Training)

โมเดลถูกฝึกบนแพลตฟอร์ม Google Colab โดยใช้ GPU (NVIDIA Tesla T4) เพื่อเพิ่มประสิทธิภาพการประมวลผลของ convolution operations ภายใน MobileNetV2 ซึ่งมีจำนวนพารามิเตอร์หลายล้านตัว การเทรนถูกแบ่งออกเป็นสองเฟสหลัก ได้แก่ Feature Extraction Phase และ Fine-Tuning Phase

6.1 การเตรียมข้อมูลก่อนการเทรน

1. การแบ่งข้อมูล (Data Splitting):

ข้อมูลภาพจากชุดข้อมูลเดิมถูกแบ่งเป็น 3 ส่วน ได้แก่

- Training set: 80%
- Validation set: 10%
- Test set: 10%

การแบ่งแบบ stratified sampling เพื่อให้สัดส่วนของแต่ละสายพันธุ์เท่ากันในทุก subset

2. การปรับขนาดภาพ (Image Preprocessing):

ภาพทั้งหมดถูกปรับขนาดเป็น 224x224 พิกเซล เพื่อให้เข้ากับ input ของ MobileNetV2 และ normalized ให้อยู่ในช่วง [0,1]

3. Data Augmentation:

เพื่อเพิ่มความหลากหลายของข้อมูลและลดปัญหา overfitting ใน training set เราใช้เทคนิค augmentation แบบสุ่ม การทำเช่นนี้ช่วยให้โมเดลเรียนรู้ลักษณะของจีโนทิปจากหลายมุมมอง แสง และพื้นหลังที่ต่างกัน

4. Batch และ Shuffle:

ใช้ batch size = 32 และ shuffle buffer = 1000 เพื่อให้การเรียนรู้มีความหลากหลายและไม่ bias ต่อข้อมูลชุดใดชุดหนึ่ง

6.2 การตั้งค่าการฝึก (Training Configuration)

Parameter	ค่า (Value)	คำอธิบาย
Optimizer	Adam	ปรับขนาดการเรียนรู้ของแต่ละ weight อัตโนมัติ ช่วยให้ converge เร็วขึ้น
Loss Function	Categorical Crossentropy	เหมาะสมกับ multi-class classification
Metrics	Accuracy	ใช้ในการติดตามความแม่นยำระหว่างเทรนและ validation
Batch Size	32	สมดุลระหว่างความเร็วและเสถียรภาพของการเรียนรู้
Epochs (รวม)	20	10 สำหรับ Feature Extraction + 10 สำหรับ Fine-tuning
Learning Rate	0.001 (Phase 1), 0.00001 (Phase 2)	ลดอัตราการเรียนรู้ในช่วง fine-tuning เพื่อป้องกันการทำลาย weight โดยไม่ต้องลดลงอย่างต่อเนื่อง

7. การประเมินผล (Evaluation)

- จากการประเมินโดยเดลตัวชี้วัดข้อมูล Validation set พบว่าโมเดลมีความแม่นยำ (Accuracy) อยู่ที่ประมาณ 89–90% ซึ่งถือว่าอยู่ในระดับสูงสำหรับงานจำแนกภาพหลายคลาส (multi-class classification) จำนวนมากถึง 75 ชนิด ขณะที่ค่า Training Accuracy อยู่ในช่วง 88–90% ซึ่งใกล้เคียงกับค่า validation อย่างมาก
- ความใกล้เคียงระหว่างค่า Training และ Validation Accuracy นี้มีความสำคัญ เพราะแสดงให้เห็นว่าโมเดลสามารถเรียนรู้ได้อย่างสมดุล — ไม่ได้ “จำข้อมูลในชุดฝึก” (overfitting) และก็ไม่ได้ “เรียนรู้ไม่เพียงพอ” (underfitting) การที่ตั้งสองส้นในกราฟ accuracy วิงค์กันตลอดช่วงการฝึกเป็นสัญญาณว่าระบบมีการ generalize ได้ดี กล่าวคือสามารถนำความรู้ที่เรียนรู้จากชุดฝึกไปใช้กับข้อมูลใหม่ที่ไม่เคยเห็นมาก่อนได้
- โดยสรุป โมเดลนี้ประสิทธิภาพพัฒนาการเรียนรู้ (training performance) และการทำงานข้อมูลใหม่ (validation performance) ซึ่งบ่งบอกว่ากระบวนการ fine-tuning ของ MobileNetV2 ที่ใช้ในงานนี้ดีพอ และสามารถนำไปต่อยอดกับข้อมูลฝึกอุดหนั่นหรือภาพจริงในสนามได้โดยไม่สูญเสียความแม่นยำมากนัก

การวิเคราะห์กราฟผลลัพธ์




Figure 3: Training and Validation Accuracy per Epoch
(กราฟแสดงความแม่นยำของชุดฝึกและชุดตรวจสอบในแต่ละ epoch)

เส้นสีน้ำเงินคือ Training Accuracy ส่วนเส้นสีส้มคือ Validation Accuracy ทั้งสองเส้นเพิ่มขึ้นใกล้เคียงกันตลอดการเทรน แสดงว่าโมเดลสามารถเรียนรู้ได้อย่างมีเสถียรภาพและไม่มีอาการ overfitting




Figure 4: Training and Validation Loss per Epoch
(กราฟแสดงค่าการสูญเสียของชุดฝึกและชุดตรวจสอบในแต่ละ epoch)

เส้นสีฟ้าแทนค่า Training Loss และเส้นสีส้มแทนค่า Validation Loss ทั้งสองลดลงต่อเนื่องและมีแนวโน้มคล้ายกัน สะท้อนว่าโมเดลเรียนรู้เพื่อลดความคลาดเคลื่อนโดยไม่ท่องจำข้อมูล

- จุดเส้นแนวตั้งคือช่วงเริ่ม Fine-tuning
- Loss ของ train และ validation ลดลงพร้อมกัน แสดงว่าไม่มี overfitting
- Accuracy ของ train และ validation ใกล้เคียงกัน แสดงถึงการ generalize ได้ดี

โมเดลสามารถจำแนกสายพันธุ์ได้ดีอย่างแม่นยำและสถิติย่อมเทียบกับ baseline ที่ใช้ random guess ($\approx 1.3\%$)

8. บทความอ้างอิงและงานที่เกี่ยวข้อง

1. Sandler, M. et al. "MobileNetV2: Inverted Residuals and Linear Bottlenecks." *CVPR 2018*
2. Chollet, F. "Deep Learning with Python." Manning, 2017.
3. Kaggle Dataset: [Butterfly Image Classification](#)
4. TensorFlow Documentation: [Transfer Learning and Fine-Tuning Guide](#)

9. สรุปผล (Conclusion)

รายการ	ค่าผลลัพธ์ที่ได้	หมายเหตุ
Training Accuracy	≈ 90%	โมเดลเรียนรู้ได้ดีและไม่ overfit
Validation Accuracy	≈ 89–90%	ความแม่นยำคงที่ในข้อมูลที่ไม่เคยเห็นมาก่อน
Test Accuracy	≈ 89%	ประสิทธิภาพใกล้เคียงกับ validation
Training Loss	ลดลงต่อเนื่องจาก ~1.2 → ~0.25	การเรียนรู้เสถียร
Validation Loss	ลดลงต่อเนื่องจาก ~1.1 → ~0.28	ไม่มีสัญญาณ overfitting
F1-Score (เฉลี่ยทุกคลาส)	≈ 0.88	โมเดลให้ผลสม่ำเสมอในแต่ละสายพันธุ์
จำนวน Epoch ทั้งหมด	20 (10 + 10 Fine-tuning)	ใช้เวลาเทรนรวมประมาณ ~40 นาทีบน GPU Colab

- โมเดลสามารถจำแนกสายพันธุ์ได้อย่างแม่นยำสูงถึงประมาณ 90%
- กราฟ loss และ accuracy ของ train/validation วิ่งใกล้กัน → แสดงถึงการ generalize ได้ดี
- ความคลาดเคลื่อนหลักเกิดในสายพันธุ์ที่มีความหลากหลายค่อนข้างมาก (เช่น *Papilio polytes* กับ *Papilio memnon*)
- โครงสร้าง MobileNetV2 ที่ผ่านการ fine-tune สามารถจับ feature เอกพักษ์ของผีเสื้อได้ดีกว่า CNN ที่ tren จากรากศูนย์
- ผลลัพธ์พิสูจน์ว่า Transfer Learning + Fine-tuning ช่วยเพิ่มประสิทธิภาพและลดเวลาเทรนได้จริง

10. การแบ่งงาน (สำหรับทำเป็นกลุ่ม)

สมาชิก	หน้าที่	สัดส่วน
นาย พิจักษณ์ ลิ้มล้ำเลิศกุล	ออกแบบและฝึกโมเดล, วิเคราะห์ผลลัพธ์	50%
นางสาว กิรณา รักประคองกิจ	เขียนรายงาน, สร้าง README.md, อธิบายผลลัพธ์และภาพ	50%